

The Design of a Practical System for Fault-Tolerant Virtual Machines

Daniel J. Scales, Mike Nelson, and Ganesh Venkitachalam

VMware, Inc.

{scales,mnelson,ganesh}@vmware.com

摘要

我们实现了一个商用企业级系统，用来提供可容错(fault-tolerant)的VM，它的原理是利用另一台服务器上的backup VM来复制primary VM的执行。我们在VMware vSphere 4.0中设计了一个完整且易于使用的系统，可以运行在通用服务器上，并且通常使真实应用的性能下降不到10%。此外对于一些真实应用，保持primary和backup的lockstep执行(译者注：lockstep可以简单理解为“步调一致”，VM-FT是复制状态机，在一定程度上保持两个VM步调一致、状态同步)所需的数据带宽低于20Mbit/s，这使得在更远距离上实现容错成为可能。一个易用的商用系统如果要在failure后自动恢复冗余，除了复制VM执行之外，还需要许多额外组件。我们设计并实现了这些额外组件，并解决了支持运行企业应用的VM时遇到的许多实际问题。本文将描述我们的基本设计，讨论可选设计方案和实现细节，并给出微基准测试和真实应用的性能结果。

1. 引言

实现可容错服务器的一种常见方法是primary/backup方法[1]，也就是始终准备一台backup服务器，在primary服务器故障(fail)时接管(take over)。backup服务器的状态必须始终与primary服务器几乎完全一致，这样当primary服务器failure时，backup服务器才能立即take over，并且以一种对外部客户端隐藏failure且不丢失数据的方式take over。复制backup服务器状态的一种方法，是几乎连续地把primary服务器所有状态的变化，包括CPU、内存和I/O设备的变化，都发送到backup服务器。然而，发送这些状态所需的带宽，尤其是内存变化所需的带宽，可能非常大。(译者注：这种方式被称为状态同步，常见的做法是先全量同步，后续同步“增量状态”，也就是上文提到的“状态变化”)

另一种复制服务器的方法有时被称为状态机(state-machine)方法[13]，它可以使用少得多的带宽。其思想是把服务器建模为deterministic state-machine：让它们从相同的初始状态开始，并确保它们以相同顺序接收相同的输入请求，从而保持同步(译者注：这个思路就是复制状态机：给相同的初始态输入相同的操作，得出的结果一样，有点机械决定论那味了)。由于大多数服务器或服务都有一些non-deterministic operation，(译者注：假设你有两台机器，都是单核心，同样的硬件配置，核心跑的同样的程序，然而它们也可能有不同的“输出”。我举个例子，你的代码里有“时间相关”的操作，即使两个机器配置一样且同时开始运行，运行期间也会由于物理因素导致的晶振频率不一致，从而让时钟中断发生的时间不一致，进而导致“时间敏感”的程序输出不同；此外，在操作系统中，随机数也是这样，它实际上综合了来自操作系统的各类“混沌的信息”，这类混沌信息也许一部分来自“时间”，因此也会有不确定性)因此必须使用额外的协调机制，确保primary服务器和backup服务器保持同步。不过，使primary服务器和backup服务器保持同步所需的额外信息量，远小于primary服务器中正在变化的状态量（主要是内存更新）。

实现协调机制来确保物理服务器的deterministic execution[14]是困难的，尤其是在处理器频率不断提高时。相比之下，运行在hypervisor之上的VM是实现state-machine方法的极好平台。VM可以被视为一个定义良好的state-machine，其操作就是被虚拟化机器（包括所有设备）的操作。与物理服务器一样，VM也有一些non-deterministic operation（例如读取日时钟，或interrupt投递），因此必须向backup VM发送额外信息，确保它保持同步。由于hypervisor完全控制VM的执行，包括所有输入的投递，因此hypervisor能够捕获primary VM上non-deterministic operation

的全部必要信息，并在backup VM上正确replay这些操作。
译者注：*hypervisor*技术可以理解为将硬件拆分给多个虚拟机使用，虽然主板上只有一套物理硬件，但是可以依靠“多路复用”的思路实现拆分。我们可以选择直接在机器上部署裸金属*hypervisor*(不依赖于操作系统)。读者可以把这种裸金属*hypervisor*理解为一个用于管理VM虚拟化的简易操作系统，在裸机安装这个“微操作系统”后，可以配置它的网络(IP、Mask、Gateway、DNS)，外界可以直接进入它的Web UI进行管理，并且它提供了Restful的API可以创建/销毁/暂停/快照虚拟机等功能，直接供外界调用，管理该机器的虚拟机资源。

实际上本文所述的FT系统，需要的主要不是“虚拟化将硬件多路复用”的能力，而是利用Hypervisor对VM执行边界的控制能力：截获输入、非确定性事件、虚拟中断、外部输出，并让backup按相同轨迹重放。实现这些能力需要修改hypervisor代码。

因此，state-machine方法可以在通用硬件上的VM中实现，不需要修改硬件，从而可以立即为最新的微处理器实现fault tolerance。此外，state-machine方法所需的低带宽，使primary和backup主机在物理上相隔更远成为可能。例如，backup VM可以运行在分布于一个园区内的物理机器上，这比运行在同一栋楼有更高的可靠性。

我们在VMware vSphere 4.0平台上使用primary/backup方法实现了fault-tolerant VM。该平台以高效方式运行完全虚拟化的x86 VM。由于VMware vSphere实现了完整的x86 VM，我们能够自动为任何x86操作系统和应用提供fault tolerance能力。使我们能够记录primary VM的执行并确保backup VM完全相同执行的基础技术称为deterministic replay[15]。VMware vSphere Fault Tolerance (FT) 基于deterministic replay，但增加了构建完整fault tolerance系统所需的额外协议和功能。除了提供硬件fault tolerance之外，我们的系统还会在failure后自动恢复冗余：它会在本地cluster中任意可用服务器上启动一个新的backup VM。目前，deterministic replay和VMware FT的生产版本都只支持单处理器VM。记录和回放多处理器虚拟机的执行过程仍处于开发阶段，存在严重的性能问题，因为几乎每次对共享内存的访问都可能是不确定的。

Bressoud和Schneider[3]描述了一个面向HP PA-RISC平台的fault-tolerant VM原型实现。我们的方法与之类似，但出于性能原因做出了一些根本改变，并考察了多种设计替代方案。此外，为了构建一个高效且可供运行企业应用的客户使用的完整系统，我们还必须设计并实现系统中的许多额外组件，并处理大量实际问题。与讨论过的




Figure 1: 基本FT配置。

大多数其他实际系统类似，我们只尝试处理fail-stop failure[12]，也就是那些能够在failed服务器造成错误的外部可见行为之前被检测到的服务器failure。

译者注：*fail-stop*可以是机器简单地直接宕机，也可以是机器尚未立刻掉电、内部状态不明，但已经不再对外产生可观察输出。对于很多服务器程序来说，客户端只能通过网络观察服务器行为；在这一前提下，如果系统能够保证某一时刻之后该服务器不再向外发送网络报文、不再响应客户端请求，那么从客户端视角看，它就可以被抽象为一种合理的*fail-stop*故障。(不过，后续读者会看到，如果该服务器还能继续写共享存储、访问外部设备或产生其他外部副作用，仅仅“不发网络包”还不够安全)

本文其余部分组织如下。首先，我们描述基本设计，并详细说明我们的基础协议，这些协议确保在backup VM于primary VM failure后take over时不会丢失数据。然后，我们会详细描述为构建一个健壮、完整、自动化的系统，我们所必须解决的许多实际问题。我们还描述实现fault-tolerant VM时出现的若干设计选择，并讨论这些选择中的权衡。

接下来，我们给出我们的实现针对若干benchmark和真实企业应用的性能结果。

最后，我们描述相关工作并作总结。

2. 基本 FT 设计

Figure 1展示了我们用于fault-tolerant VM的系统基本设置。对于一个希望提供fault tolerance能力的VM(primary VM),我们会在另一台物理服务器上运行一个backup VM,使它保持同步，并以与primary VM完全相同的方式执

行,只是有很小的时间滞后。我们称这两个VM处于virtual lockstep(译者认为可以称为“步调一致”)状态。VM的virtual disk位于shared storage上(例如Fibre Channel或iSCSI disk array),因此primary VM和backup VM都可以访问这些磁盘以进行输入和输出(我们将在section 4.1讨论一种primary VM和backup VM使用独立的非共享virtual disk的设计)。只有primary VM会在网络上宣告自己的存在,因此所有network input(译者注:网络报文)都会到达primary VM。类似地,所有其他输入(例如键盘和鼠标)也只会到达primary VM。(译者注:如果通过VNC连接VM内的Linux那么键盘和鼠标也算network input;当然vSphere Web Console/VMRC的控制台会直接向VM的虚拟键盘/鼠标设备注入事件,因此确实存在keyboard/mouse input。VMware官方资料也明确讨论了Web Console和VMRC中的键鼠事件。读者可以暂时不感知keyboard/mouse,就假设咱们只能VNC,通篇论文只关注网络和磁盘相关即可)

primary VM收到的所有输入都会通过一条称为logging channel的网络连接发送给backup VM。对于服务器的工作负载而言,主要的输入流量来自网络和磁盘。如下文section 2.1所述,为了确保backup VM与primary VM以相同的方式执行non-deterministic operation,必要时还会传输额外信息(这里后续会提到,backup不接收自己机器上的timer中断,也不会收到来自外界的报文,而是通过logging channel稍带这些信息,使得它们被插入到和primary VM相同的执行点,以消除状态偏移)。结果是,backup VM始终以与primary VM完全相同的方式执行。

不过,backup VM的输出会被hypervisor丢弃,因此只有primary VM会产生实际输出并返回给客户端。如section 2.2所述,primary VM和backup VM遵循一个特定协议,其中包括backup VM的显式acknowledgment,以确保primary VM failure时不会丢失数据。

译者注:“丢数据”指的是primary已经对外产生了某个可见结果,但backup没有收到足够的log来重放到这个结果对应的状态。

为了检测primary VM或backup VM是否已经发生故障,我们的系统结合使用了两种机制:相关服务器之间的心跳检测,以及对logging channel上流量的监控。除此之外,即使出现primary服务器和backup彼此失去通信的这种脑裂情况,(译者注:常见的一种脑裂情况是两台服务器分区,彼此无法通讯,后面两台机器都认为自己是primary)我们也必须确保primary VM和backup VM中只有一个会接管执行。

在下面各节中,我们将对几个重要方面给出更多细

节。在section 2.1,我们给出deterministic replay技术的一些细节,该技术通过logging channel发送的信息确保primary VM和backup VM保持同步。在section 2.2,我们描述FT协议的一条基本规则,它确保primary VM failure时不会丢失数据。在section 2.3,我们描述用于以正确方式检测并响应failure的方法。

2.1 deterministic replay的实现

如前所述,复制服务器(或VM)的执行可以被建模为复制一个deterministic state-machine。如果两个deterministic state-machine从相同的初始状态开始,并以相同顺序获得完全相同的输入,那么它们将经历相同的状态序列,并产生相同的输出。VM具有广泛的input集合,包括传入的network packet、disk read,以及来自键盘和鼠标的input。non-deterministic event(例如virtual interrupt)和non-deterministic operation(例如读取处理器的时钟周期计数器)也会影响VM的状态。由于VM可能运行任意操作系统和任意工作负载(译者注:不能假定VM只运行类似“纯计算”的任务,也得考虑是否会读取系统时间,或者进行某些依赖系统时间片的工作。实际上network就是这样的工作,tcp协议其实内部会依赖定时器),这为VM的执行带来了三个挑战:(1)正确捕获保证backup VM deterministic execution所需的所有输入和non-determinism;(2)正确地把这些输入和non-determinism应用到backup VM;(3)以不降低性能的方式做到这一点。此外,x86微处理器中的许多复杂操作具有未定义的、因而也是non-deterministic的副作用。捕获这些未定义副作用并replay它们以产生相同状态,是另一个挑战。

VMware deterministic replay[15]正是为VMware vSphere平台上的x86 VM提供了这种功能。deterministic replay会把VM的输入以及与VM执行相关的所有可能的non-determinism,record为一串log entry并写入log file。之后通过读取文件中的log entry,可以精确replay VM的执行。对于non-deterministic operation,会记录足够的信息,使该操作能够以相同的状态变化和输出被复现。对于timer interrupt或IO完成interrupt等non-determinism事件,还会record事件发生时的精确指令。在replay期间,该事件会在指令流中的同一位置被投递。VMware deterministic replay实现了一种高效的事件record和事件投递机制,采用了多种技术,包括与AMD[2]和Intel[8]共同开发的硬件性能计数器。

Bressoud和Schneider[3]提到把VM的执行划分为若干epoch,诸如interrupt这样的non-deterministic event只在一




Figure 2: FT协议。

一个epoch结束时投递。epoch的概念似乎被用作一种批处理机制，因为在事件发生的精确指令处分别投递每个interrupt成本太高。然而，我们的事件投递机制足够高效，因此VMware deterministic replay不需要使用epoch。每个interrupt都会在发生时被记录，并在replay时高效地投递到适当的指令处。

译者注：先简要描述Bressoud和Schneider的epoch机制。该系统同样采用primary/backup架构，两台机器上都有一种特殊寄存器，该寄存器会在每执行完一条指令后递减一次；当其变为负数时，处理器会触发一个控制中断，使hypervisor重新获得控制权。例如，如果将该寄存器设置为1000，那么按照字面语义，VM会在执行完1001条指令后结束当前epoch，并陷入由该特殊寄存器触发的控制中断。此时hypervisor可以统一处理本epoch内存存起来的普通VM中断。这里的普通VM中断，是指timer interrupt、I/O完成interrupt、network interrupt等guestOS正常运行时会看到的中断，它们不同于用于结束epoch的控制中断。

对于primary和backup来说，它们从相同状态启动，并且各自的hypervisor都会将该特殊寄存器设置为相同的值，例如1000。在一个epoch内，primary收到的普通VM中断不会立即投递给primary VM，而是先由primary hypervisor记录并缓存起来；backup本机收到的普通VM中断也不会直接投递给backup VM，而是由backup hypervisor丢弃。primary VM和backup VM会执行对应的epoch，但backup至少落后primary一个epoch。当primary的epoch结束时，primary hypervisor把本epoch内存存的普通VM中断列表发送给backup，并等待ack。backup执行到对应epoch边界后，等待并接收该中断列表，先向primary返回ack，再向backup VM投递同一批中断。primary收到ack后，才在自己的epoch边界向primary VM投递这批中断；随后双方分别进入下一个对应的epoch。

2.2 FT协议

对于VMware FT，我们使用deterministic replay来生成必要的日志条目，用来记录primary VM的执行过程。但我们不是把这些log entry写入磁盘，而是通过logging channel把它们发送给backup VM。backup VM会实时replay这些log entry，因此以与primary VM完全相同的方式执行。不过，为了确保真正实现fault tolerance，我们必须在logging channel上的log entry之外增加严格的FT协议。我们的基本要求如下：

Output Requirement: 如果backup VM在primary VM failure后take over，那么backup VM将继续以一种完全符合primary VM已经发送到外部世界的所有输出的方式执行。

注意，在发生failover之后（也就是backup VM在primary VM failure后take over之后），由于执行过程中会发生许多non-deterministic event，backup VM很可能开始以一种与primary VM原本继续执行时非常不同的方式执行。不过，只要backup VM满足**Output Requirement**，在failover到backup VM的过程中就不会丢失任何外部可见的状态或数据，客户端也不会察觉服务中断或不一致。

Output Requirement可以通过delay任何外部输出（通常是一个网络包）来保证，直到backup VM已经接收到所有必要信息，使其能够至少将执行重放到该输出操作发生的位置。一个必要条件是，backup VM必须已经接收到该输出操作之前生成的所有日志条目。这些日志条目将使它能够执行到最后一个日志条目所在的位置。然而，假设primary VM在执行完输出操作后立即发生故障，backup VM就必须知道自己必须继续replay，直到该输出操作的位置，并且只能在那个位置“上线”（也就是停止重放，并接管成为primary VM，见section 2.3）。如果备份虚拟机在输出操作之前的最后一个日志条目处就上线（go live），那么某些non-deterministic event（例如传递给VM的timer interrupt）可能会在它执行该输出操作之前改变它的执行路径。

在上述约束下，强制执行**Output Requirement**最简单的方法，是在每个output operation处创建一个特殊的log entry。于是，**Output Requirement**可以通过下面这条具体规则来强制执行：

Output Rule: 在backup VM收到并acknowledge与产生该output的操作相关联的log entry之前，primary VM不得向外部世界发送该输出。

如果backup VM已经收到所有log entry，包括产生输出的操作对应的log entry，那么backup VM就能够精确复现primary VM在该输出点处的状态；因此，如果primary VM死亡，backup VM将正确到达一个与该输出一致的状态。相反，如果backup VM在没有收到所有必要log entry的情况下take over，那么它的状态可能很快发散，导致与primary VM的输出不一致。**Output Rule**在某种程度上类似于[11]中描述的方法，其中“外部同步”的IO实际上可以被缓冲，只要它在下一次外部通信之前确实写入磁盘即可。

注意，**Output Rule**并没有要求停止primary VM的执行。我们只需要delay发送输出，而VM本身可以继续执行(译者注：这也是为什么这个系统能较少地影响机器性能的部分原因)。由于操作系统使用非阻塞的网络和磁盘输出，并通过异步interrupt表示完成，VM可以很容易继续执行，并且不一定会立即受到输出delay的影响。相比之下，以前的工作[3, 9]通常指出，primary VM在执行输出之前必须完全停止，直到backup VM acknowledge已收到来自primary VM的所有必要信息。(译者注：比如前面的epoch，primary和backup都会停在执行完某个epoch之后，然后这里会暂停primary VM，等到交互完成后双方才能继续执行。因此这个系统虽然是“批处理”思想的系统，但也是性能损失较大的)

作为示例，我们在Figure 2中展示了一张说明FT协议要求的图。该图展示了primary VM和backup VM上事件的时间线。从primary VM线指向backup VM线的箭头表示log entry的传输，从backup VM线指向primary VM线的箭头表示acknowledgment。异步事件、输入和output operation的信息都必须作为log entry发送到backup VM，并得到acknowledgment。如图所示，到外部世界的输出会被delay，直到primary VM收到backup VM的acknowledgment，表明backup VM已经收到与该output operation相关联的log entry。只要遵循Output Rule，backup VM就能够以一种与primary VM最后一次输出一致的状态take over。

我们无法保证在failover场景中所有输出都恰好产生一次。如果在primary VM打算发送输出时不使用带two-phase commit的transaction，backup VM就无法判断primary VM是在发送最后一个输出之前还是之后崩溃。幸运的是，network infrastructure（包括TCP的常见使用方式）本来就是为了解决丢失包和相同的（重复）包而设计的。注意，primary VM的传入包也可能在primary VM failure期间丢失，因此不会被投递到backup VM。不过，传入包可能因为许多与服务器failure无关的原因被丢弃，因此network in-

frastructure、操作系统和应用都被编写成能够补偿丢包。译者注：

这里并不能保证packet恰好发送一次。primary可能在最后一个packet真正发出之前或之后failure，因此客户端可能观察到丢包或重复包。Output Rule保证的是：只要某个输出已经对外可见，backup就拥有足够的log，可以在failover后到达与该输出一致的状态。TCP等网络协议本来就会处理丢包、重复和乱序，因此FT层不需要判断最后一个packet究竟是否发出。磁盘I/O不能完全依赖这种网络协议语义，相关处理见section 3.4。

2.3 检测并响应failure

如上所述，如果另一个VM看起来已经failure，primary VM和backup VM必须快速响应。如果backup VM failure，primary VM将go live，也就是离开recording mode（因此停止在logging channel上发送log entry）并开始正常执行(译者注：实际上这里go live上线用词不妥，它的意思仅仅是退出recording mode，变成独立运行/不受保护的模式，并不代表之前就不是“live”的)。如果primary VM failure，backup VM也应类似地go live，但这个过程稍微复杂一些。由于backup VM的执行存在滞后，它很可能已经接收并acknowledge了若干log entry，但由于尚未到达执行中的相应位置，这些log entry还没有被消费而被堆积。backup VM须继续执行并消费日志，直到最后一条log entry被重放，此时，backup VM将停止replay模式，并开始作为普通VM执行。本质上，backup VM已被提升为primary VM（但此时它缺少一个backup VM）。由于它不再是backup VM，新的primary VM现在会在guest OS执行output operation时向外部世界产生输出。在切换到正常模式期间，可能需要进行一些设备相关的操作，才能使这些输出正确发生。特别是对于网络，VMware FT会自动在网络上宣告新primary VM的MAC地址，使物理网络交换机知道新primary VM位于哪台服务器(译者注：这样后续来自客户端的网络报文才能继续被处理)。此外，新提升的primary VM可能需要重新发出一些磁盘IO（如section 3.4所述）。

尝试检测primary VM和backup VM failure的方法有很多。VMware FT使用运行fault-tolerant VM的服务器之间的UDP heartbeat来检测某台服务器是否可能已经崩溃。此外，VMware FT会监控从primary VM发送到backup VM的logging traffic，以及从backup VM发送到primary VM的acknowledgment。由于有定期的timer interrupt，对于正常运行的guest OS，logging traffic应当是规律的，且不会停止。因此，log entry或acknowledgment的流动停止可能表明某

个VM发生failure。如果heartbeat或logging traffic停止超过某个特定超时时间（大约几秒），就会宣布发生failure。

然而，任何这样的failure detection方法都容易受到split-brain问题的影响。如果backup服务器停止接收来自primary服务器的heartbeat，这可能表示primary服务器已经failure，也可能只是表示仍在正常运行的服务器之间失去了所有网络连通性(译者注：也就是backup和primary发生分区，互相无法ping到对方，UDP的heartbeat心跳包也发不过去，都认为对方死亡)。如果此时backup VM go live，而primary VM实际上仍在运行，那么很可能发生数据损坏，并给与VM通信的客户端带来问题。因此，当检测到failure时，我们必须确保primary VM和backup VM中只有一个go live。为了避免split-brain问题，我们利用存储VM virtual disk的shared storage。当primary VM或backup VM想要go live时，它会在shared storage上执行一个atomic的test-and-set操作。如果操作成功，该VM就被允许go live。如果操作失败，那么另一个VM一定已经go live，因此当前VM实际上会停止自身（“自杀”）。如果VM在尝试执行该atomic操作时无法访问shared storage，那么它只会等待，直到可以访问为止。注意，如果shared storage由于存储网络中的某种failure而不可访问，那么该VM很可能无论如何都无法做有用工作，因为virtual disk位于同一个shared storage上。因此，使用shared storage解决split-brain情况不会引入额外的不可用性。

译者注：论文中的shared storage不是由guestOS直接访问的网络盘，也不是挂载在guestOS文件系统层中的对象。它通常是hypervisor层可以共同访问的共享存储，例如SAN、iSCSI、FC或NFS datastore。VM的virtual disk存放在该shared storage上，hypervisor再把这个virtual disk模拟成一块普通磁盘设备呈现给guestOS。guestOS看到的是类似/dev/sda这样的本地块设备，并在其上挂载自己的文件系统；但真正把虚拟磁盘I/O映射到sharedstorage读写的是hypervisor/VMkernel，而不是guestOS的网络栈。

可见test-and-set的操作也是guestOS无感知的，完全由hypervisor层进行。

设计的最后一个方面是，一旦发生failure并且其中一个VM已经go live，VMware FT会通过另一台host上启动新的backup VM来自动恢复冗余。虽然大多数先前工作没有覆盖这个过程，但它对于使fault-tolerant VM真正有用是根本性的，并且需要仔细设计。更多细节见section 3.1。

3. FT的实际实现

section 2描述了FT的基本设计和协议。然而，要创建一个可用、健壮且自动化的系统，还必须设计并实现许多其他组件。

3.1 启动和重启FT VM

必须设计的最大额外组件之一，是一种能够以与primary VM相同状态启动backup VM的机制。这个机制也会发生在发生failure之后重新启动backup VM时使用。因此，该机制必须能够用于一个处于任意状态的正在运行的primary VM（也就是说，并不只是用于启动阶段）。此外，我们希望该机制不会显著干扰primary VM的执行，因为这会影响该VM当前的任何客户端。

对于VMware FT，我们改造了VMware vSphere现有的VMotion功能。VMware VMotion[10]允许把一个正在运行的VM从一台服务器迁移到另一台服务器，并且造成的干扰很小，VM暂停时间通常小于一秒。我们创建了一种修改后的VMotion，它会在远程服务器上创建一个VM的精确运行副本，但不会销毁本地服务器上的VM。也就是说，我们修改后的FT VMotion会把一个VM克隆到远程host，而不是迁移它。FT VMotion还会建立logging channel，并使源VM以primary VM身份进入recording mode，使目标VM以新backup VM身份进入replay mode。与普通VMotion一样，FT VMotion通常使primary VM的执行暂停不到一秒。因此，在一个正在运行的VM上启用FT是一个简单且非破坏性的操作。

译者注：老式操作系统可能主要依赖timer interrupt来推进系统时间。例如，硬件每10ms产生一次定时器中断，那么内核收到10次中断后，就认为大约过去了100ms。现代操作系统通常不会仅靠这种周期性tick来计算当前时间，而是会选择某个clocksource，例如x86机器上的TSC（Time Stamp Counter，CPU时间戳计数器），或者虚拟化环境中的paravirtual clock。调用gettimeofday时，系统会读取当前clocksource的计数值，与内核timekeeper中保存的基准计数值（如cycle_last）相减，将cycle差值换算成纳秒，再加入到内核维的wallclock基准时间上，最后返回给用户态。很多系统还会通过vDSO在用户态完成这一步，避免每次都陷入内核。

针对VM暂停和迁移，读者可能会问：在复制期间，如果VM大约暂停了1s，是否会导致VM内部读到的时间落后现实世界时间（wallclock）1s？可以这样理解：如果系统真的完全依赖timer interrupt计数来推进时间，并且暂停期间




Figure 3: FT日志缓冲区和通道。

没有收到这些中断，那么恢复后确实可能出现时间落后；但现代虚拟化环境通常不会简单依赖补发timer interrupt来追赶时间。hypervisor可以通过虚拟化TSC、虚拟时钟偏移、paravirtual clock或时间同步机制，让guest OS在下次读取clocksource或调用gettimeofday时看到已经校正后的wallclock(real world clock)。因此，VM暂停1s后，不需要向guest OS连续注入大量timer interrupt来弥补这1s。wallclock的推进和timer interrupt的注入是两个不同层面的问题；VM恢复时，hypervisor会根据虚拟定时器的类型和语义处理已经过期的timer，可能合并或投递timer interrupt，并不保证固定补发一个中断。

启动backup VM的另一个方面，是选择在哪个服务器上运行它。fault-tolerant VM运行在能够访问shared storage的服务器cluster中，因此所有VM通常都可以在cluster中的任意服务器上运行。这种灵活性使VMware vSphere即使在一台或多台服务器已经failure时，也能恢复FT冗余。VMware vSphere实现了一个维护管理和资源信息的cluster服务。当发生failure并且某个primary VM现在需要一个新的backup VM来重新建立冗余时，primary VM会通知clustering service它需要一个新的backup。clustering service根据资源使用情况和约束确定运行backup VM的最佳服务器，并调用FT VMotion来创建新的backup VM。结果是，VMware FT通常能够在服务器failure后的几分钟内重新建立VM冗余，并且整个过程不会对fault-tolerant VM的执行造成任何可察觉的interrupt。

3.2 管理logging channel

管理logging channel上的流量涉及一些有趣的实现细节。在我们的实现中，hypervisor为primary VM和backup VM维护一个大的log entry缓冲区。当primary VM执行时，它会把log entry生成到log buffer中；类似地，backup VM会从自己的log buffer消费log entry。primary VM log buffer的内容会尽快刷新到logging channel，log entry也会在到达后尽快从logging channel读入backup VM的log buffer。backup VM每次从网络读入一些log entry到自己的log buffer时，都会向primary VM发送acknowledgment。这些acknowledgment使VMware FT能够确定那些被Output Rule delay的输出何时可以发送。Figure 3展示了这一过程。（译者注：log entry包含，例如timer interrupt、network input、disk I/O completion的信息）

如果backup VM在需要读取下一条log entry时遇到空的log buffer，它会停止执行，直到有新的log entry可用。由于backup VM不与外部通信，这种暂停不会影响VM的任何客户端。类似地，如果primary VM在需要写入log entry时遇到满的log buffer，它必须停止执行，直到log entry能够被刷新出去。这种执行停止是一种自然的流控机制，会在primary VM过快产生log entry时降低其速度。然而，这种暂停可能影响VM的客户端，因为primary VM会完全停止并且无响应，直到它能够record log entry并继续执行。因此，我们的实现必须被设计成尽量降低primary log buffer被填满的可能性。

译者注：下面是简化的primary执行与日志生成伪代码；实际实现还包含并发的日志发送、ACK处理和buffer回收逻辑：

```
func PrimaryRunLoop(vm *VM) {
    for vm.Running {
        result := RunGuestUntilExitOrEvent(vm)

        switch result.Type {

        case "DETERMINISTIC_EXECUTION":
            // 普通CPU指令、内存读写、guestOS内部逻辑
            // 不写log，backup自己也能执行出来
            continue

        case "NONDETERMINISTIC_EVENT":
            // 例如timer interrupt、network input、disk I/O
            // completion
            entry := LogEntry{
                Seq:      NextSeq(),
                EventType: result.EventType,
                InstrCount: vm.InstrCount(),
                Payload:   result.Payload,
            }

            // 关键：primary把非确定性事件写入自己的logbuffer
```

```

primaryLogBuffer.Append(entry)

// 然后才把这个事件注入/交给guest
InjectEventToGuest(vm, entry)

case "OUTPUT_OPERATION":
    // guest想对外输出, 比如发网络包
    // 注意: output本身可能是deterministic产生的,
    // 但它有外部副作用, 所以要遵守OutputRule

    entry := LogEntry{
        Seq:      NextSeq(),
        EventType: "OUTPUT_MARKER",
        InstrCount: vm.InstrCount(),
        Payload:    nil,
    }

    primaryLogBuffer.Append(entry)

    output := PendingOutput{
        Packet:      result.Packet,
        RequiredSeq: entry.Seq,
    }

    // 不能马上发出去, 先放到pending队列
    pendingOutputs.Append(output)

case "VM_FAIL_OR_STOP":
    return
}
}

func HandleBackupAck(ackedSeq uint64) {
    primaryLogBuffer.ReleaseThrough(ackedSeq)

    for pendingOutputs.HasReady(ackedSeq) {
        output := pendingOutputs.PopReady(ackedSeq)
        SendToExternalWorld(output.Packet)
    }
}

```

如果Append因buffer已满而无法继续, primary执行循环就必须等待。日志发送循环把entry发送给backup; 收到ACK后, ACK处理逻辑回收已确认的log entry, 并释放满足Output Rule的pending output。

primary log buffer可能被填满的一个原因, 是backup VM执行得太慢, 因而消费log entry也太慢。一般来说, backup VM必须能够以大致等于primary VMrecord执行的速度来replay执行。幸运的是, 在VMware deterministic replay中, record和replay的开销大致相同。然而, 如果承载backup VM的服务器上运行了许多其他VM (因而资源过度提交), 那么即使backup hypervisor的VM调度器尽力调度, backup VM也可能无法获得足够的CPU和内存资源来以primary VM的速度执行。

译者注: 这里的内存资源不足, 并不是说guest OS看到的内存容量变小了。创建VM时确实会指定一个内存大小, 例如4GB或8GB, guest OS也会认为自己拥有这么多“物理

内存”。但是这只是guest看到的guest physical memory大小, 这些guest物理页背后仍然需要宿主机(host)真实物理内存承载。如果承载backup VM的机器上运行了很多VM, 所有VM配置的内存总量可能超过物理机的真实物理内存, 这就是memory overcommit, 也就是内存超卖。此时hypervisor可能通过ballooning、memory compression、host swapping、page sharing等机制回收或腾挪内存页。如果host物理内存实在不够, hypervisor也可能从其他VM回收分配给该VM的物理页; 直观地说, 这有点像向其他VM“借”内存, 但不是把另一台VM整体永久暂停后直接搬走它的内存。更准确地说, hypervisor可以把其他VM中暂时不用、可回收或者优先级较低的页面压缩后放入host内存中的压缩区, 或者写入host swap所在的磁盘空间, 也可以通过ballooning让该guest OS主动释放一些页面, 再把释放出来的host物理页分配给当前更需要资源的VM。被回收页面的VM通常仍然可以继续运行, 但如果它之后再次访问这些被压缩或换出的页面, 就需要等待hypervisor重新解压或从swap读回, 因此会发生短暂停顿。更底层地说, guest OS维护自己的页表, 把guest virtual address映射到guest physical address; hypervisor还会维护二级地址映射, 例如Intel EPT或AMD NPT, 把guest physical address映射到host physical address。当某个guest物理页暂时没有映射到host物理页时, guest再次访问该页不会由guest OS自己处理, 而是触发EPT violation或nested page fault, 使CPU退出到hypervisor。随后hypervisor把该页从swap中读回, 或者解压、重新分配host物理页, 并恢复对应的二级页表映射。这个过程更准确地说是在VM-exit, 不是普通外部中断。它不会改变guest OS看到的内存大小, 但会增加内存访问延迟。因此backup VM虽然名义上仍拥有创建时配置的内存容量, 却可能因为host层面的物理内存竞争、换页、向其他VM回收页面, 或者NUMA局部性变差而replay变慢。

除了避免log buffer被填满导致意外暂停之外, 我们不希望执行滞后变得太大还有另一个原因。如果primary VM failure, backup VM必须通过replay它已经acknowledged的所有log entry来“追上来”, 然后才能go live并开始与外部世界通信。完成replay所需时间基本上就是failure发生点的执行滞后时间, 因此backup VM go live所需时间大致等于failure detection时间加上当前执行滞后时间。因此, 我们不喜欢执行滞后时间很大 (超过一秒), 因为这会显著增加failover (故障接管) 的时间。(译者注: 因为backup必须重放完, 直到处理完最后一条log entry)

因此, 我们有一个额外机制来降低primary VM的速度, 防止backup VM落后太多。在发送和acknowledgment log entry的协议中, 我们会发送额外信息, 以确定primary

VM和backup VM之间的实时执行滞后。通常执行滞后小于100毫秒。如果backup VM开始出现显著执行滞后（例如超过1秒），VMware FT会通过通知调度器给primary VM略少一些CPU（开始时只减少几个百分点）来减慢primary VM。我们使用一个缓慢的反馈循环，逐步找出适合primary VM的CPU限制，使backup VM能够匹配其执行。如果backup VM继续落后，我们会继续逐步降低primary VM的CPU限制。相反，如果backup VM追上来了，我们会逐步提高primary VM的CPU限制，直到backup VM恢复到只有轻微滞后。

译者注：**Output Rule**会把对外输出额外延迟到backup VM ACK对应log entry之后。在游戏服务器中，这个延迟尤其影响用户体验，假如ack时间是40ms那么游戏服务器的出包延迟很可能就会多出接近40ms，有的游戏玩家根本接受不了这种延迟。

注意，primary VM的这种减速非常少见，通常只会在系统处于极端压力下发生。section 5中的所有性能数字都包含了任何这类减速的成本。

3.3 FT VM上的操作

另一个实际问题是处理可能应用于primary VM的各种控制操作。例如，如果primary VM被显式关机，backup VM也应停止，而不应尝试go live。再如，primary VM上的任何resource management变化（例如增加CPU份额）也应应用到backup VM。对于这类操作，会通过logging channel从primary VM向backup VM发送特殊的control entry，以便在backup VM上执行相应操作。

一般来说，对VM的大多数操作都只应在primary VM上发起。VMware FT随后会发送必要的control entry，使backup VM发生相应变化。唯一可以在primary VM和backup VM上独立执行的操作是VMotion。也就是说，primary VM和backup VM可以独立地VMotion到其他host。注意，VMware FT会确保两个VM都不会被移动到另一个VM所在的服务器上，因为那种情况将不再提供fault tolerance能力。

primary VM的VMotion比普通VMotion增加了一些复杂性，因为backup VM必须在适当时刻断开与源primary VM的连接，并重新连接到目标primary VM。backup VM的VMotion也有类似问题，但还增加了额外复杂性。对于普通VMotion，我们要求在VMotion最终切换发生时，所有未完成的磁盘IO都被静止（也就是完成）。对于primary VM，通过等待物理IO完成并把这些完成投递给VM，就

很容易处理这种静止。然而，对于backup VM，没有简单方法能在任何要求的位置使所有IO都完成，因为backup VM必须replay primary VM的执行，并在相同的执行点完成IO。primary VM可能正在运行一种workload，在正常执行期间始终有磁盘IO正在进行。VMware FT有一种独特方法来解决这个问题。当backup VM到达VMotion的最终切换点时，它会通过logging channel请求primary VM临时静止其所有IO。随后，backup VM在replay primary VM的静止操作执行时，它自己的IO也会自然地在同一个执行点被静止。

译者注：这是说了两个问题：一是primary从一台host迁移到另外一台；二是backup从一台host迁移到另外一台。其中后者更难一点。

primary迁移可以理解为：在最终切换点暂停primary VM，等待所有in-flight磁盘I/O完成，并把这些I/O completion交付进VM的虚拟设备状态/待处理中断状态中，从而形成一个没有inflight disk I/O的干净迁移点。随后旧primary停止运行，把旧VM状态切换到新host，并且配置网络，新primary从该状态继续执行。backup则在正确的log边界断开旧primary，并连接新primary。此后新primary继续作为primary记录non-determinism事件，生成log entry，并通过新的logging channel发送给backup。

backup迁移比primary迁移更麻烦：原因是backup VM并不是自由执行的VM，而是在replay primary VM的执行流；因此backup不能为了迁移而任意选择一个时刻交付磁盘I/O completion，否则就可能破坏和primary相同的执行轨迹。当backup VMotion进入最终切换阶段时，backup会通过logging channel请求primary暂时quiesce磁盘I/O。primary执行这个quiescing operation，等待已有in-flight磁盘I/O完成，并把completion交付给VM；该操作随后被记录进FT log。backup在replay primary执行流时，会在同一个执行点replay到这个quiescing operation，于是backup的I/O也自然进入quiesced状态。此时backup才可以安全地完成迁移，旧backup停止运行，目标主机上的backup从该状态继续replay primary后续产生的log。

3.4 磁盘IO的实现问题(重要，难点)

与磁盘IO相关的实现问题有许多微妙之处。首先，由于disk operation是非阻塞的，因此可以并行执行(译者注：现代网卡发送通常也采用类似的异步提交模型：驱动填写descriptor并通知设备，设备通过DMA处理数据，随后

报告完成),同时访问同一disk location的并发disk operation可能导致non-determinism。此外,我们的磁盘IO实现使用DMA直接读写VM的内存,因此同时访问同一内存页的并发磁盘操作也可能导致non-determinism。我们的解决方案通常是检测任何这样的IO竞争(这种情况很少见),并强制这些竞争的disk operation在primary VM和backup VM上以相同方式顺序执行。

译者注:这里讨论的是同一个VM提交的并发磁盘操作。如果多个操作访问相同的disk location或guest memory page,不同的执行或完成顺序可能产生不同结果;VMware FT需要检测这类IO竞争,并保证它们在primary和backup上按照相同顺序串行执行。这不是primary和backup之间争用shared disk。

典型disk read流程是:驱动在内存中填写I/O descriptor,其中包含磁盘位置、长度和目标内存位置,再写doorbell寄存器通知设备。控制器读取磁盘后通过DMA写入目标内存,并报告completion。disk write则由控制器通过DMA读取待写数据。在默认设计中,disk read返回的数据及其completion是input,会通过log提供给backup; disk write是output。非共享磁盘设计会让backup执行disk write,而让backup执行disk read是section 4.2讨论的另一项独立设计。

其次,disk operation也可能与VM中应用(或OS)的内存访问竞争,因为disk operation通过DMA直接访问VM的内存。例如,如果VM中的应用/OS正在读取一个内存块,同时又有另一个disk read正在读入该内存块,就可能产生non-determinism结果。这种情况也不太可能发生,但一旦发生,我们必须检测并处理它。一种解决方案是临时对作为disk operation目标的页面设置page protection。如果VM恰好访问了一个也是未完成disk operation目标的页面,page protection会导致一次trap,VM可以被暂停直到disk operation完成。由于更改页面上的MMU保护是昂贵操作,我们选择改用bounce buffers。bounce buffers是一个临时缓冲区,其大小与disk operation访问的内存相同。disk read操作被修改为把指定数据读到bounce buffers中,并且只有在IO完成被投递时,才把数据复制到guest内存。类似地,对于disk write操作,要发送的数据会先复制到bounce buffers,disk write也被修改为从bounce buffers写出数据。使用bounce buffers可能减慢disk operation,但我们没有看到它造成任何可察觉的性能损失。

译者注:这里是一个具体的edge case,我们仔细讲。

现在有一个primary和backup,primary中的guest OS发起了一次disk read,请求把某个磁盘block读入guest内存页A;后续guest CPU又会执行读取内存页A的指令。由

于磁盘IO是异步的,如果不加控制,磁盘设备可能会通过DMA在某个不可控时刻把数据写入A。在primary上,guest提交读操作后不久直接读内存A,primary可能读到的是老数据,也可能是从磁盘数据读出来的数据,甚至由于我们没有等待中断,可能是混杂数据。而backup由于通常落后primary一段时间,等它replay到读取A的指令时,很明显,它读的就是A内存的老数据,不可能是磁盘数据或者混杂数据。这样primary和backup在同一条读取指令上就可能读到不同的值,从而导致VM状态分叉。正常驱动通常会等待completion后才把数据当作有效结果使用,但错误驱动、恶意guest或其他并发内存访问仍可能触发这种竞争,因此hypervisor必须保证行为确定。

解决办法是使用bounce buffer。primary发生disk read时,hypervisor不让磁盘设备直接DMA写入guest内存页A,而是先把数据DMA到hypervisor的临时缓冲区bounce buffer中;当磁盘IO完成时暂停VM,将bounce buffer内存数据拷贝进内存A,并向guest注入磁盘完成的interrupt,记录下此刻的CPU计数器用来生成log entry发给log buffer,随即恢复VM执行。backup在replay时也会遇到guest提交disk read的动作;在默认设计中,backup不会把该请求真正发往磁盘,而是等待primary记录的read结果和completion。后续读取内存A时,它会读到旧值,当停到上面提到的来自primary的disk interrupt log entry后,backup的hypervisor才会暂停VM,紧接着在拿着log entry里的信息在内存A里面写数据并且注入interrupt。

第三,当failure发生且backup VM执行take over时,primary VM上in-flight的磁盘IO会带来一些问题。新提升的primary VM无法确定这些磁盘IO是否已经发往磁盘,或是否已经成功完成。此外,由于这些磁盘IO没有在backup VM上对外发出,随着新提升的primary VM继续运行,也不会有明确的IO完成返回给它们,这最终会导致VM中的guest操作系统启动abort或reset过程。我们可以发送一个错误完成,表示每个IO都失败了,因为即使IO已经成功完成,返回错误也是可接受的。然而,guest OS可能无法很好地处理来自本地磁盘的错误。相反,我们在backup VM的go live过程中重新发出这些待处理IO。由于我们已经消除了所有竞争,并且所有IO都直接指定了访问哪些内存和disk block,因此即使这些disk operation已经成功完成,也可以重新发出它们(也就是说,它们是幂等的)。

译者注: hypervisor向外发网络包和hypervisor向共享磁盘发请求,表面上都属于VM对外部世界的output,因此都受到Output Rule约束:一个output至少要等到backup

确认收到足够的log之后, *primary*才可以真正把它释放到外部世界;在此之前,该*output*只能暂存在*hypervisor*中。

对于网络报文, **Output Rule**只保证: 如果某个*packet*已经对外可见, 那么*backup*一定已经拥有足够的log, 可以在*failover*后进入与该输出一致的状态。但是, **Output Rule**并不保证*primary*释放*packet*之后, 该*packet*一定已经完整通过物理网卡发出。*primary*可能在*packet*尚未真正发出、只发出一部分、或者已经完整发出之后发生*failure*。*backup*无法区分这些情况, 也不会去在*go live*之后补发这个*packet*。原因是网络本身允许丢包、重复和乱序: 如果*packet*没有真正发出去, 可以视为普通网络丢包; 如果*packet*已经发出去, *backup*再补发反而可能制造重复输出。对于TCP, 这类丢包或重复会由序号、ACK和重传机制处理; 对于UDP, 则本来就允许丢包。因此, 网络输出的不确定性可以被网络协议语义吸收, FT层不需要也不应该猜测并补发旧*packet*。

磁盘I/O则不同。*guest OS*把本地磁盘看作块设备, 请求发出后通常期待一个明确的I/O completion。如果old *primary*上的*pending disk I/O*已经发往共享存储, 但*backup*原先并没有真正发出这些I/O, 那么*backup*接管后也不会自然收到这些completion。若什么都不做, *guest OS*中的块设备请求会悬挂; 若直接返回本地磁盘错误, 又可能触发*abort*或*reset*流程。因此, VMware FT选择在*backup go live*过程中重新发出这些*pending disk I/O*。这里能够重发, 并不是因为磁盘I/O天然像网络协议一样支持任意重传, 而是因为系统已经消除了I/O竞争, 并且每个I/O都明确指定了访问的*guest memory*范围和*disk block*范围。在这些条件下, 普通*block read/write*可以被安全地重新执行: 同一份数据重复写入同一批*block*不会改变最终磁盘状态; 没有竞争写入时, 重新读取同一批*block*也会得到一致结果。具体实现可能是:

*hypervisor*在虚拟磁盘设备层维护一张*pending disk I/O*表。每当*guest OS*向虚拟磁盘控制器提交一个I/O请求时, *hypervisor*就创建一条*PendingDiskIO*记录, 其中包含请求类型、访问的*disk block*范围、目标*guest memory*范围、对应的*bounce buffer*、请求状态以及completion是否已经交付给*guest*等信息。对于*write*, *hypervisor*会先把*guest memory*中要写出的数据复制到*bounce buffer*, 再从*bounce buffer*向共享存储发出真实*write*; 这样即使*guest*随后修改原内存页, 这个*write*请求的数据内容也保持稳定。对于*read*, *hypervisor*不会让真实磁盘DMA直接写入*guest memory*, 而是先读入*bounce buffer*, 等到一个确定的I/O

completion投递点时, 才把*bounce buffer*中的数据复制到*guest memory*, 并更新虚拟磁盘设备状态、向*guest*注入完成中断。在*primary*上, *PendingDiskIO*会被真正提交给共享存储; 物理I/O完成后, 该请求并不会立刻从*pending*表中删除, 因为*guest*还没有看见completion。只有当*hypervisor*在确定执行点把completion交付给*guest*之后, 该I/O才算从*pending disk I/O*状态结束。此时*hypervisor*还会把这个completion事件及其确定执行位置记录到FT log中, 使*backup*可以在相同的*guest*执行点交付同一个completion。在*backup*上, *guest*提交I/O的动作也会被replay出来, 因此*backup hypervisor*也会创建对应的*PendingDiskIO*记录; 但在正常*backup*状态下, 它通常不会把这些I/O真正发往共享存储, 而只是维护虚拟磁盘设备中的*pending*状态。当*backup replay*到*primary*发来的completion log entry时, 才按照log在相同执行点更新*guest memory*和虚拟设备状态, 并把completion交付给*guest*; 此后该I/O也从*backup*的*pending*表中移除。如果*primary*发生*failure*, *backup*首先replay完已经收到的FT log, 然后*go live*。此时*backup*扫描自己的*pending disk I/O*表: 凡是已经replay到completion并交付给*guest*的I/O, 不需要重发; 凡是尚未向*guest*交付completion的I/O, 则按照表中保存的原始I/O描述重新提交给共享存储。对于*write*, 重新提交的是*bounce buffer*中保存的同一份数据和同一批*disk block*; 对于*read*, 重新读取的是同一批*disk block*, 完成后再把结果交付给*guest*。这里的重发不是从*guest*应用或文件系统层重新执行一次操作, 而是在*hypervisor*层重新提交已经存在于虚拟磁盘设备状态中的*pending block I/O*。由于系统已经消除了相关I/O竞争, 并且每个I/O都明确指定了访问的*guest memory*范围和*disk block*范围, 因此这些普通*block read/write*可以在*failover*时被安全地重新执行。

3.5 网络IO的实现问题

VMware vSphere为VM网络提供了许多性能优化。其中一些优化基于*hypervisor*异步更新VM网络设备的状态。例如, *hypervisor*可以在VM执行时直接更新接收缓冲区。不幸的是, 这些对VM状态的异步更新引入了non-determinism。除非我们能保证所有更新都发生在*primary VM*和*backup VM*指令流中的同一位置, 否则*backup VM*的执行就可能偏离*primary VM*。

为了支持FT, 对网络仿真代码做出的最大改动, 是禁用异步网络优化。原本会用传入包异步更新VM ring buffer的代码, 已经被修改为强制*guest trap*到*hypervisor*; 在*hypervisor*中, 系统可以记录这些更新, 然后再把它们应用

到VM。类似地，通常会从transmit queue异步取出包的代码在FT中也被禁用，发送改为通过一次到hypervisor的trap完成（下面注明的例外除外）。

消除网络设备的异步更新，再加上section 2.2所述的发送包latency，给网络性能带来了一些挑战。在运行FT时，我们采用两种方法来提升VM网络性能。首先，我们实现了聚合优化以减少VM trap和interrupt。当VM以足够的比特率流式传输数据时，hypervisor可以对一组包只执行一次发送trap；在最佳情况下甚至可以零trap，因为它可以在接收新包的过程中发送这些包。同样，hypervisor也可以通过只为一组包投递一次interrupt，减少传入包触发给VM的interrupt数量。

我们的第二个网络性能优化，是减少发送包的latency。如前所述，hypervisor必须delay所有发送包，直到它从backup VM收到相应log entry的acknowledgment。减少发送latency的关键，是减少向backup VM发送日志消息并获得acknowledgment所需的时间。我们在这方面的主要优化，是确保发送和接收log entry与acknowledgment都可以在没有任何thread context switch的情况下完成。VMware vSphere hypervisor允许向TCP栈注册函数，使其在收到TCP数据时从deferred-execution上下文（类似Linux中的tasklet）中被调用。这使我们能够在没有任何thread context switch的情况下，快速处理backup VM上收到的任何日志消息，以及primary VM上收到的任何acknowledgment。此外，当primary VM将一个待发送包入队时，我们会通过调度一个deferred-execution上下文来执行刷新，从而强制立即刷新相关联的输出log entry（如section 2.2所述）。

4. 设计替代方案

在VMware FT的实现中，我们探索了若干有趣的设计替代方案。本节将讨论其中一些方案。

4.1 共享磁盘与非共享磁盘

在我们的默认设计中，primary VM和backup VM共享同一组virtual disk。因此，如果发生failover，共享磁盘的内容自然是正确且可用的。本质上，共享磁盘被认为位于primary VM和backup VM之外，所以对共享磁盘的任何写入都被视为一次到外部世界的通信。因此，只有primary VM会实际写入磁盘，并且对共享磁盘的写入必须按照Output Rule进行delay。

另一种设计是让primary VM和backup VM拥有独立




Figure 4: FT非共享磁盘配置。

的（非共享的）virtual disk。在这种设计中，backup VM确实会对自己的virtual disk执行所有disk write；这样做时，它自然会使自己virtual disk的内容与primary VM virtual disk的内容保持同步。Figure 4展示了这种配置。在非共享磁盘的情况下，virtual disk本质上被视为每个VM内部状态的一部分。因此，primary VM的disk write不必按照Output Rule进行delay。当primary VM和backup VM无法访问shared storage时，non-shared设计非常有用。造成这种情况的原因可能是shared storage不可用或成本太高，也可能是运行primary VM和backup VM的服务器距离很远，即所谓“long-distance FT”（译者注：shared storage如果离primary/backup很远，那么性能差）。非共享设计的一个缺点是，当首次启用fault tolerance时，必须以某种方式显式同步两份virtual disk。此外，failure后磁盘可能变得不同步，因此在failure后重启backup VM时必须显式重新同步。也就是说，FT VMotion不仅必须同步primary VM和backup VM的运行状态，还必须同步它们的磁盘状态。

在非共享磁盘配置中，可能没有shared storage可用于处理split-brain情况。在这种情况下，系统可以使用其他外部仲裁者，例如一台两台服务器都能通信的第三方服务器。如果这些服务器属于一个包含两个以上节点的cluster，系统也可以使用基于cluster成员关系的majority算法。在这种情况下，只有当某个VM运行在一个能够通信的子cluster中的服务器上，并且该子cluster包含原始节点的多数时，该VM才允许go live。

译者注：这种设计可以在backup take over的时候不用再猜old primary对shared disk的pending write是否已经生效。但

是缺点也有，就是建立一个`backup`难度大，磁盘数据的全量拷贝是很慢的。还有一个缺点是需要自己用额外的方式避免脑裂。

4.2 在backup VM上执行disk read

在我们的默认设计中，`backup VM`从不读取自己的`virtual disk`（无论磁盘是共享的还是非共享的）。由于`disk read`被视为输入，因此很自然地把`disk read`结果通过`logging channel`发送给`backup VM`。（译者注：发出`disk read`请求本身要和`disk read`返回结果区分开。`guest OS`提交`read`请求只是虚拟磁盘设备状态的一次变化，`backup`在`replay guest`指令流时也会建立同样的`pending read request`；`primary hypervisor`随后向真实磁盘发出的`physical read`只是为了取得一个外部输入，并不改变磁盘的逻辑内容，因此通常不被视为`Output Rule`中的`output`。真正作为`input`进入`VM`的是`read`返回的数据以及对应的`I/O completion`事件。`primary`必须记录读到的数据和`completion`被投递的执行位置，`backup`则在相同位置把同一数据交付给`guest`）

另一种设计是让`backup VM`执行`disk read`，从而消除对`disk read`数据的日志`record`。对于执行大量`disk read`的`workload`，这种方法可以显著减少`logging channel`上的流量。

然而，这种方法有许多微妙之处。它可能减慢`backup VM`的执行，因为`backup VM`必须执行所有`disk read`；当`backup VM`到达`primary VM`中这些读取完成的执行点时，如果它们在物理上尚未完成，`backup VM`就必须等待。

此外，还必须做一些额外工作来处理失败的`disk read`操作。如果`primary VM`的`disk read`成功，但`backup VM`对应的`disk read`失败，那么`backup VM`的`disk read`必须不断重试，直到成功，因为`backup VM`必须在内存中获得与`primary VM`相同的数据。相反，如果`primary VM`的`disk read`失败，那么目标内存的内容必须通过`logging channel`发送给`backup VM`，因为内存内容将是不确定的，并且不一定能通过`backup VM`的成功`disk read`来复制。

最后，如果把这种`disk read`替代方案用于共享磁盘配置，还会有一个微妙问题。如果`primary VM`读取某个特定`disk location`，并且很快又写入同一`disk location`，那么该`disk write`必须`delay`，直到`backup VM`已执行第一次`disk read`。这种依赖关系可以被检测并正确处理，但会给实现增加额外复杂性。

在section 5.1，我们给出一些性能结果，表明在`backup VM`上执行`disk read`会使真实应用的吞吐量略微下降（1-

	performance (FT / non-FT)	logging bandwidth
SPECJbb2005	0.98	1.5 Mbits/sec
Kernel Compile	0.95	3.0 Mbits/sec
Oracle Swingbench	0.99	12 Mbits/sec
MS-SQL DVD Store	0.94	18 Mbits/sec

Table 1: 基本性能结果。

4%)，但也会明显降低日志带宽。因此，在`logging channel`带宽相当有限的情况下，在`backup VM`上执行`disk read`可能是有用的。

5. 性能评估

本节对VMware FT在若干应用`workload`和网络`benchmark`上的性能做一个基本评估。对于这些结果，我们把`primary VM`和`backup VM`分别运行在配置相同的两台服务器上，每台服务器都有八个Intel Xeon 2.8GHz CPU和8 Gbytes内存。两台服务器通过10 Gbit/s交叉`network connection`，不过正如后面将看到的，在所有情况下使用的网络带宽都远低于1 Gbit/s。两台服务器都通过标准的4 Gbit/s Fibre Channel网络访问连接到EMC Clariion的共享`virtual disk`。用于驱动部分`workload`的客户端通过1 Gbit/s `network connection`到服务器。

我们在性能结果中评估的应用如下。SPECJbb2005是一个行业标准的Java应用`benchmark`，它非常占用CPU和内存，但几乎不执行IO。Kernel Compile是一个运行Linux内核编译的`workload`。该`workload`会进行一些`disk read`和`disk write`，并且由于会创建和销毁许多编译进程，它非常占用CPU和MMU。Oracle Swingbench是一个`workload`，其中Oracle 11g数据库由Swingbench OLTP（在线`transaction`处理）`workload`驱动。该`workload`会执行大量磁盘和网络IO，并有八十多个并发数据库会话。MS-SQLDVD Store是一个工作负载，其中Microsoft SQL Server 2005数据库由DVD Store基准测试驱动，该`benchmark`有十六个并发客户端。

5.1 基本性能结果

Table 1给出了基本性能结果。对于列出的每个应用，第二列给出在运行服务器`workload`的VM上启用FT时的应用性能，与同一VM上未启用FT时性能的比值。性能比值的计算方式是：小于1的值表示FT`workload`较慢。显然，对于这些代表性`workload`，启用FT的开销小于10%。SPECJbb2005完全受计算限制，没有空闲时间，

但表现良好，因为除了timer interrupt之外，它几乎没有non-deterministic event。其他workload会执行磁盘IO，并且有一些空闲时间，因此部分FT开销可能会被FT VM空闲时间较少这一事实隐藏。不过，总体结论是，VMware FT能够以相当低的性能开销支持fault-tolerant VM。

在表的第三列，我们给出运行这些应用时在logging channel上发送数据的平均带宽。对于这些应用，日志带宽相当合理，并且很容易由1 Gbit/s网络满足。事实上，低带宽需求表明多个FT workload可以共享同一个1 Gbit/s网络，而不会产生任何负面性能影响。

对于运行Linux和Windows这类常见guest操作系统的VM，我们发现guest OS空闲时的典型日志带宽为0.5-1.5 Mbit/s。“空闲”带宽主要来自record timer interrupt的投递。对于具有活跃workload的VM，日志带宽主要由必须发送给backup VM的网络和磁盘输入决定，也就是接收到的network packet以及从disk read得到的disk block。因此，对于网络接收或disk read带宽非常高的应用，日志带宽可能远高于Table 1中测得的数值。对于这类应用，logging channel的带宽可能成为瓶颈，尤其是在logging channel还有其他用途时。

许多真实应用在logging channel上所需的带宽相对较低，这使基于replay的fault tolerance对于使用非共享磁盘的远距离配置非常有吸引力。对于primary VM和backup VM可能相隔1-100公里的远距离配置，光纤很容易支持100-1000 Mbit/s的带宽，并且latency小于10毫秒。

对于Table 1中的应用，100-1000 Mbit/s的带宽应当足以获得良好性能。不过要注意，primary VM和backup VM之间额外的往返latency可能导致网络和磁盘输出最多delay 20毫秒。远距离配置只适用于那些客户端能够容忍每个请求增加这种额外latency的应用。

对于两个磁盘最密集的应用，我们测量了在backup VM上执行disk read(如section 4.2所述)相对于通过logging channel发送disk read数据的性能影响。对于Oracle Swingbench，在backup VM上执行disk read时throughput约低4%；对于MS-SQLDVD Store，throughput约低1%。同时，Oracle Swingbench的日志带宽从12Mbit/s降至3Mbit/s，MS-SQLDVD Store的日志带宽从18Mbit/s降至8Mbit/s。显然，对于disk read带宽大得多的应用，带宽节省可能大得多。如section 4.2所述，当disk read在backup VM上执行时，性能预计会稍差一些。不过，在logging channel带宽受限的场景中（例如远距离配置），在backup VM上执行disk read可能是有用的。

	base bandwidth	FT bandwidth	logging bandwidth
Receive (1Gb)	940	604	730
Transmit (1Gb)	940	855	42
Receive (10Gb)	940	860	990
Transmit (10Gb)	940	935	60

Table 2: 网络发送和接收性能。

5.2 网络benchmark

出于若干原因，网络benchmark对我们的系统可能非常具有挑战性。首先，高速网络可能具有非常高的interrupt率，这要求以非常高的速率record和replay异步事件。其次，以高速率接收包的benchmark会导致很高的logging traffic，因为所有这些包都必须通过logging channel发送给backup VM。第三，发送包的benchmark会受到Output Rule的约束；该规则会delay network packet的发送，直到收到来自backup VM的相应acknowledgment。这种latency会增加客户端测得的latency。它也可能降低面向客户端的网络带宽，因为network protocol（例如TCP）可能不得不在往返latency增加时降低网络传输速率。

Table 2给出了我们使用标准netperf benchmark进行若干测量的结果。在所有这些测量中，客户端VM和primary VM通过1 Gbit/s network connection。前两行给出primary host和backup host通过1 Gbit/s logging channel连接时的发送和接收性能。第三、第四行给出primary服务器和backup服务器通过10 Gbit/s logging channel连接时的发送和接收性能；与1 Gbit/s网络相比，它不仅带宽更高，而且latency更低。作为粗略度量，1 Gbit/s连接上hypervisor之间的ping时间约为150微秒，而10 Gbit/s连接上的ping时间约为90微秒。

未启用FT时，primary VM的发送和接收可以接近1 Gbit/s的线速（940 Mbit/s）。当为接收workload启用FT时，日志带宽非常大，因为所有传入network packet都必须在logging channel上发送。因此，logging channel可能成为瓶颈，这一点在1 Gbit/s logging network的结果中可以看到。对于10 Gbit/s logging network，这种影响小得多。当为发送workload启用FT时，发送包的数据不会被record，但网络interrupt仍然必须record。日志带宽低得多，因此可达到的网络发送带宽高于网络接收带宽。总体来看，我们发现FT在非常高的发送和接收速率下会显著限制网络带宽，但仍然能够达到很高的绝对速率。

6. 相关工作

Bressoud和Schneider[3]描述了完全在hypervisor层通过软件为VM实现fault tolerance的最初思想。他们通过一个面向HP PA-RISC处理器服务器的原型,证明了让backup VM与primary VM保持同步的可行性。然而,由于PA-RISC架构的限制,他们无法实现完全安全且隔离的VM。此外,他们没有实现任何failure detection方法,也没有尝试解决section 3描述的任何实际问题。更重要的是,他们对自己的FT协议施加了一些不必要的约束。首先,他们引入了epoch的概念,在这种机制中,异步事件会被delay到一段固定间隔结束时才投递。epoch的概念并不是必要的;他们可能采用它,是因为他们无法足够高效地replay单个异步事件。其次,他们要求primary VM基本停止执行,直到backup VM已经接收并acknowledge所有先前log entry。然而,必须delay的只是输出本身(例如network packet), primary VM本身可以继续执行。

Bressoud[4]描述了一个在操作系统(Unixware)中实现fault tolerance的系统,因此它为运行在该操作系统上的所有应用提供fault tolerance能力。系统调用接口成为必须被deterministically复制的一组操作。该工作与基于hypervisor的工作具有类似的限制和设计选择。

Napper等人[9]以及Friedman和Kama[7]描述了fault-tolerant Java VM的实现。他们采用了与我们类似的设计,即在logging channel上发送关于输入和non-deterministic operation的信息。与Bressoud一样,他们似乎没有关注failure detection以及failure后重新建立fault tolerance。此外,他们的实现只限于为运行在Java VM中的应用提供fault tolerance。这些系统试图处理多线程Java应用的问题,但要求所有数据都被锁正确保护,或者强制对共享内存的访问进行串行化。

Dunlap等人[6]描述了一种deterministic replay的实现,目标是在半虚拟化系统上调试应用软件。我们的工作支持运行在VM内部的任意操作系统,并为这些VM实现fault tolerance支持,这需要高得多的稳定性和性能水平。

Cully等人[5]描述了另一种支持fault-tolerant VM的方法,以及一个名为Remus的项目中的实现。采用这种方法时, primary VM的状态会在执行期间被反复checkpoint,并发送到backup服务器,由backup服务器收集这些checkpoint信息。checkpoint必须非常频繁地执行(每秒多次),因为外部输出必须被delay,直到后续checkpoint已经发送并被acknowledge。这种方法的优点是,它同样适用于单处理器和多处理器VM。主要问题是,这种方法需要非常高的网络带宽,用于在每次checkpoint时发送内存状态的增量

变化。[5]中给出的Remus结果显示,在尝试使用1 Gbit/s network connection来传输内存状态变化、每秒执行40次checkpoint时, Kernel Compile和SPECwebbenchmark的执行时间会增加100%到225%。有一些优化可能有助于降低所需网络带宽,但尚不清楚使用1 Gbit/s连接能否获得合理性能。相比之下,我们基于deterministic replay的方法,对于若干真实应用,可以实现低于10%的开销,并且primary host与backup host之间所需带宽低于20Mbit/s。

7. 结论和未来工作

我们在VMware vSphere中设计并实现了一个高效且完整的系统,为运行在服务器cluster中的VM提供fault tolerance (FT) 能力。我们的设计基于使用VMware deterministic replay,通过另一台host上的backup VM复制primary VM的执行。如果运行primary VM的服务器failure, backup VM会立即take over,不会interrupt服务,也不会丢失数据。

总体而言,在通用硬件上,VMware FT下fault-tolerant VM的性能非常出色,并且对一些典型应用表现出低于10%的开销。VMware FT的大部分性能成本来自使用VMware deterministic replay保持primary VM和backup VM同步的开销。因此,VMware FT的低开销来自VMware deterministic replay的高效率。此外,使primary VM和backup VM保持同步所需的日志带宽通常相当小,常常低于20Mbit/s。由于在大多数情况下日志带宽很小,实现primary VM和backup VM相隔较远距离(1-100公里)的配置似乎是可行的。因此,VMware FT可以用于同时防护整个站点failure这类灾难的场景。值得注意的是,logging流通常相当容易压缩,简单的压缩技术只需少量额外CPU开销,就能显著降低日志带宽。

我们使用VMware FT得到的结果表明,可以在deterministic replay之上构建一个高效的fault-tolerant VM实现。这样的系统能够以极低开销,透明地为运行任意操作系统和应用的VM提供fault tolerance能力。然而,要使一个fault-tolerant VM系统对客户有用,它还必须健壮、易于使用并且高度自动化。一个可用系统需要许多超出VM复制执行本身的其他组件。特别是,VMware FT会在failure后自动恢复冗余,方法是在本地cluster中找到合适的服务器,并在该服务器上创建新的backup VM。通过解决所有必要问题,我们展示了一个可用于客户数据中心真实应用的系统。

通过deterministic replay实现fault tolerance的一个权衡是,目前deterministic replay只在单处理器VM上得到了高效实现。不过,对于种类繁多的workload,单处理器VM

已经绰绰有余,尤其是物理处理器仍在持续变得更强。此外,许多workload可以通过使用多个单处理器VM向外扩展,而不是使用一个更大的多处理器VM向上扩展。面向多处理器VM的高性能replay是一个活跃研究领域,并且有可能通过微处理器中的一些额外硬件支持来实现。一个有趣方向可能是扩展transaction内存模型,以促进多处理器replay。

未来,我们也有兴趣扩展系统,以处理部分硬件failure。所谓部分硬件failure,是指服务器中部分功能或冗余丧失,但不会导致数据损坏或丢失。一个例子是VM失去所有网络连通性,或者物理服务器中一个冗余电源failure。如果运行primary VM的服务器发生部分硬件failure,在许多情况下(但不是全部情况),立即failover到backup VM将是有利的。这样的failover可以立即为关键VM恢复完整服务,并确保该VM被快速迁离一台可能不可靠的服务器。

致谢

我们感谢Krishna Raja,他生成了许多性能结果。有许多人参与了VMware FT的实现。deterministic replay(包括对多种虚拟设备的支持)以及基础FT功能的核心实现者包括Lan Huang、Eric Lowe、Slava Malyugin、Alex Mirgorodskiy、Kaustubh Patil、Boris Weissman、Petr Vandrovec和Min Xu。此外,还有许多其他人参与了VMware vCenter中FT的更高层管理工作。Karyn Ritter出色地管理了大量相关工作。

8. 参考文献

- [1] Alsberg, P., and Day, J. A Principle for Resilient Sharing of Distributed Resources. In Proceedings of the Second International Conference on Software Engineering (1976), pp. 627–644.
- [2] AMD Corporation. AMD64 Architecture Programmer’s Manual. Sunnyvale, CA.
- [3] Bressoud, T., and Schneider, F. Hypervisor-based Fault Tolerance. In Proceedings of SOSP 15 (Dec. 1995).
- [4] Bressoud, T. C. TFT: A Software System for Application-Transparent Fault Tolerance. In Proceedings of the Twenty-Eighth Annual International Symposium on Fault-Tolerance Computing (June 1998), pp. 128–137.
- [5] Cully, B., Lefebvre, G., Meyer, D., Feeley, M., Hutchison, N., and Warfield, A. Remus: High Availability via Asynchronous Virtual Machine Replication. In Proceedings of the Fifth USENIX Symposium on Networked Systems Design and Implementation (Apr. 2008), pp. 161–174.
- [6] Dunlap, G. W., King, S. T., Cinar, S., Basrai, M., and Chen, P. M. ReVirt: Enabling Intrusion Analysis through Virtual Machine Logging and Replay. In Proceedings of the 2002 Symposium on Operating Systems Design and Implementation (Dec. 2002).
- [7] Friedman, R., and Kama, A. Transparent Fault-Tolerant Java Virtual Machine. In Proceedings of Reliable Distributed System (Oct. 2003), pp. 319–328.
- [8] Intel Corporation. Intel® 64 and IA-32 Architectures Software Developer’s Manuals. Santa Clara, CA.
- [9] Napper, J., Alvisi, L., and Vin, H. A Fault-Tolerant Java Virtual Machine. In Proceedings of the International Conference on Dependable Systems and Networks (June 2002), pp. 425–434.
- [10] Nelson, M., Lim, B.-H., and Hutchins, G. Fast Transparent Migra-

tion for Virtual Machines. In Proceedings of the 2005 Annual USENIX Technical Conference (Apr. 2005).

[11] Nightingale, E. B., Veeraraghavan, K., Chen, P. M., and Flinn, J. Rethink the Sync. In Proceedings of the 2006 Symposium on Operating Systems Design and Implementation (Nov. 2006).

[12] Schlichting, R., and Schneider, F. B. Fail-stop Processors: An Approach to Designing Fault-tolerant Computing Systems. ACM Computing Surveys 1, 3 (Aug. 1983), 222–238.

[13] Schneider, F. B. Implementing fault-tolerance services using the state machine approach: A tutorial. ACM Computing Surveys 22, 4 (Dec. 1990), 299–319.

[14] Stratus Technologies. Benefit from Stratus Continuing Processing Technology: Automatic 99.999% Uptime for Microsoft Windows Server Environments. At <http://www.stratus.com/~media/-Stratus/Files/Resources/WhitePapers/continuousprocessing-for-windows.pdf>, June 2009.

[15] Xu, M., Malyugin, V., Sheldon, J., Venkitachalam, G., and Weissman, B. ReTrace: Collecting Execution Traces with Virtual Machine Deterministic Replay. In Proceedings of the 2007 Workshop on Modeling, Benchmarking, and Simulation (June 2007).